

1 背景介绍

Gowalla最早是2009年推出的地理位置社交网站，用户可以在地图上“签到”分享位置。

Gowalla数据集包含两个文件：

Gowalla_edges.txt：记录用户之间的好友关系，共196591个用户节点，950327条好友关系边（无向图）。

Gowalla_totalCheckins.txt：6442890条签到记录，包含每次签到的用户、时间、经纬度等信息。

数据时间范围：2009-02-04至2010-10-23。

2 方法

统计分析

基于用户好友关系构建图网络，基于 `networkx` 库统计每个用户节点的度、用户的平均聚类系数（ CC ）、网络全局聚类系数、网络连通性与直径（使用 `approximate_diameter` 计算近似直径），并使用 `powerlaw` 库自动拟合幂律分布的 α, x_{min} 参数。

社区分析

使用Louvain算法查找不重叠社区（时间复杂度 $O(N\log N)$ ），并分析最大的5个社区与10个中等规模社区的成员签到位置分布。

中等规模社区选取为规模排序100~190的社区，对应用户数量由20到9不等。

演化分析

此部分将用户第一次签到视为“节点加入网络”。

按月统计网络中用户数量、签到次数累计与新增量随时间变化，并使用幂律与Gompertz模型对完整的19个月进行拟合。

Gompertz模型： $y(t) = ae^{-be^{-ct}}$ ，表现为早期增长缓慢，中期快速增长，最终达到饱和，上界为 a 。

定义生命周期为用户第一次与最后一次签到时间间隔，仅签到一次的用户生命周期为1；对生命周期与对应用户数量进行统计分析。

推荐算法

使用基于历史地理位置、好友关系与POI热门程度的推荐。

Step 1 加载数据：好友关系与签到数据。

Step 2 过滤用户：在用户网络中，仅保留进行过签到的用户。

Step 3 编码用户与POI：使用 `sklearn.LabelEncoder` 将用户与POI ID编码为整数，并对同一ID的POI坐标平均处理。

Step 4 划分训练集/测试集：每名用户的签到记录按时间顺序，前80%作为训练集，后20%作为测试集。

Step 5 构建用户POI历史：{user_id: [poi_id]}。

Step 6 构建好友关系：{user_id: [friend_id]}。

Step 7 聚合好友POI：对5000名用户，计算并保留好友签到最多的50个POI。
假设好友签到的POI对该用户更有吸引力。

Step 8 构建POI索引：将坐标构建为KD树，提高查询速度 ($O(\log n)$) 。

Step 9 计算热门POI：统计全局签到次数前10的POI。
当用户历史记录不足时，可使用热门POI进行推荐。

Step 10 融合推荐：基于地理 (G)、好友 (S) 与热门 (H) 因素对POI进行评分与推荐。

Step 10.1 候选集：在历史POI中选取10个，选取附近50个POI，并加入好友签到与全局热门POI；排除用户已签到POI，且候选集大于3000时随机采样到3000个。

Step 10.2 计算得分。

G：基于候选POI与所有历史POI的距离计算相似度（历史POI大于300时采样到300）。

POI的地理得分 $SG_i = \frac{1}{k} \sum_{j=1}^k \exp(-\frac{d_{ij}^2}{2\sigma^2})$ ，其中 k 为历史POI数量（归一化， $k = 0$ 时直接返回 $SG = 0$ ）， d_{ij} 为POI的经纬度欧式距离， σ 为高斯核衰减参数（取0.2）。

S：在好友中签到次数最多的POI对应为1，其他好友签到过的POI按次数比例对应0~1。

H：根据POI在全局签到次数的排名 r_i ，对应得分 $SH_i = \frac{1}{r_i}$ 。

Step 10.3 综合得分并推荐。

最终得分 $S_i = w_G SG_i + w_S SS_i + w_H SH_i$ ，排序并返回Top-10。

Step 11 评估：

对Top-10推荐的POI，检查是否落在至少一个POI的0.05度（对应经线距离约5.5km）范围内。
每组对200名随机用户进行评估（不同配置选取的用户相同）。

Step 11.1 定义指标：

$Hit > 0$ ：至少推荐一个真实POI的用户比例。

$Precision$ （精确率）：推荐POI中，落在真实POI附近的数量。

$Recall$ （召回率）：用户所有感兴趣的POI中，被推荐出的数量。

Step 11.2 定义权重：


配置	w_G	w_S	w_H
G	1.0	0.0	0.0
S	0.0	1.0	0.0
H	0.0	0.0	1.0

配置	w_G	w_S	w_H
G+S	0.6	0.4	0.0
G+H	0.6	0.0	0.4
G+S+H	0.5	0.3	0.2

3 结果

网络与节点属性


在log-log坐标下，用户节点度与节点数量关系如下图。
 在度大于一定值时，度分布满足幂律（Power-law）。



幂律分布的拟合参数 α, x_{min} :

α : 2.8081697548517583, x_{min} : 83.0

如下图，幂律拟合在度大于83时有效，而在尾部（度大于200）出现偏离，呈现截断幂律特征。




平均 CC : 0.2367, 对应随机图 G_{np} 的 CC 为 $4.917 * 10^{-5}$ (取节点数与期望边数与Gowalla网络相同) ; 全局 CC : 0.0235。


网络最大连通分量包含196591节点, 即网络连通; 近似直径为16。

社区划分与地理统计


网络共划分为866个社区, 其中最大5个社区的节点数量为34689、27375、27165、11866、11450。
log-log坐标下社区规模与社区数量关系如下图, 社区规模在(3, 28)符合幂律分布且衰减较快, 在(28, 34689)近似水平 (重尾分布) 。



前5个社区成员的签到位置如下图。每个社区的实际签到次数约300k~1M, 图中每个社区仅随机选取5k个用户、10k个点进行绘制。




10个中等大小社区的成员签到位置如下图。





大规模社区全球均有分布，大部分集中于美国与西欧；5个社区成员的签到点的分布没有显著差异。部分小规模社区签到点呈现地理聚集性。

网络演化与生命周期分析

下图中柱状图为当月新增用户或签到，折线图为累计用户或签到。




幂律与Gompertz模型拟合结果如下。



	幂律拟合 R^2	Gompertz拟合 R^2
用户	0.9871	0.9975
签到	0.9958	0.9987

12723位 (11.9%) 仅签到一次；如下图，多次签到的用户数量与生命周期呈现幂律分布，存在部分用户的签到次数达到日均1次。



基于地理位置-好友-热门POI的推荐

对四类不同的权重配置，推荐结果指标如下，其中POI匹配阈值为0.05度。

配置	$Hit > 0$	$Precision$	$Recall$
G	0.780	0.7550	2.2840
S	0.130	0.4810	1.4301
H	0.850	0.0130	0.0312
G+S	0.755	0.7075	1.9985
G+H	0.755	0.6725	1.8248
G+S+H	0.795	0.7205	1.8781

由于地理位置使用阈值匹配，一个推荐POI可能对应多个邻近的真实POI，因此 $Recall$ 可能大于1。

以下为针对其中一位用户推荐的Top-5 POI (G) ，该用户具有102个历史POI。

POI ID	坐标	地理得分 SG
185	(30.2636,-97.7396)	0.6379
186	(30.2653,-97.7385)	0.5292
161	(30.2678,-97.7415)	0.5067
166	(30.2685,-97.7362)	0.4854
495364	(30.2636,-97.7396)	0.4753

对纯地理 (G) 的推荐，选取不同POI匹配阈值对100位用户进行匹配，结果如下。

POI匹配阈值	$Hit > 0$	$Precision$	$Recall$
0	0.10	0.0200	0.0042
0.001	0.15	0.0480	0.1692
0.005	0.34	0.2240	0.5381
0.01	0.41	0.3440	1.0906
0.02	0.56	0.4730	1.0662
0.05	0.79	0.7530	2.4673
0.1	0.86	0.8590	2.8326
0.2	0.87	0.8600	2.5745
0.5	0.88	0.8800	2.3097
1	0.92	0.9040	2.6609

4 讨论

网络与社区属性

统计分析结果表明，Gowalla网络的度分布符合无标度网络特征，且存在具有大量（10k以上）用户连接的“Hub用户”，且大规模社区的形成更有可能基于兴趣或Hub用户。
较低的全局 CC 同样表明大量用户关注Hub用户，但彼此并没有建立好友联系。

网络中同时存在大量小规模社区，且节点平均 CC 显著高于随机图，表明图网络的局部连接紧密，小社区可能基于现实关系构建（如朋友、同学之间也可能相互认识）。

地理属性

大规模社区的签到点分布具有全球性，且社区之间签到点分布没有显著差异，表明这些社区的形成更有可能基于兴趣或Hub用户，而非地理分布。

签到点集中于美国与西欧，可能由于Gowalla起源于美国，而西欧文化背景相似更容易推广。

小规模社区的地理聚集性，则印证LBSN网络基于地理位置的社交构建特性，以及这些社区更可能基于现实关系构建。

推荐结果同样表现该特性。纯地理（G）具有最精准的推荐效果，加入好友POI（S）与全局热门POI（H）导致*Precision*与*Recall*均出现不同程度降低，即用户更倾向于访问一定地理范围或活动半径内的地点，而非可能较远的热门POI（如城市地标）或好友签到的POI（在大社区中，用户与好友的距离可能较远）。

G+S+H在用户覆盖率 $Hit > 0$ 上略有提高，而H尽管精度显著低于加入G的推荐配置，但具有最高的覆盖率，说明融合模型虽然降低了平均精度，但能让更多用户获得至少一个有效推荐。

选取不同POI阈值进行G推荐时，各指标在阈值0.05度时均出现明显提升，估计用户的活动半径大致在0.02-0.1度（约2.2~11km）之间，可用于进行城市级POI推荐。

网络演化

对用户与签到数量的幂律与Gompertz模型均有较好拟合结果；Gompertz模型预测的用户上限约为当前用户数的1.52倍，签到上限约为当前签到数的2.88倍，表明Gowalla在数据截止时仍处于增长期，远未达到饱和。

同时，尽管2010年3月的新增用户数量明显高于其他月份（大于前一个月的2倍），但用户与签到数量均表现出平稳增长趋势，未形成显著“爆发增长”。

局限与展望

出于设备性能与推理时间考虑，本项目直接指定了推荐过程的参数与GSH权重，并未对这些参数进行优化。同时对推荐算法进行了一定简化处理：

使用全局热门POI代替用户偏好；使用平均聚合获取好友POI；基于高斯核计算地理位置相似性，而实际地理距离分布可能呈现幂律；随机采样用于计算的用户与数据签到样本。

推荐部分尝试过协同过滤算法，但由于时间、空间开销均过高，且随机采样会破坏数据完整性与有效性，因此未获得有效结果。

5 总结

本项目对Gowalla地理位置社交网络进行了多维度分析。

网络具有无标度 ($\alpha=2.81$) 和小世界 (平均聚类系数0.237, 直径16) 特征;

社区规模呈重尾分布, 大规模社区兴趣驱动, 小规模社区地理聚集。演化分析表明用户增长符合幂律与Gompertz模型, 网络仍处于增长期。

推荐实验表明纯地理模型优于融合社交与热度的混合模型, 用户活动半径约为5公里。

综合结果表明, 地理邻近性是LBSN中用户签到行为的主导因素, 网络结构、演化规律与用户行为三者高度一致。